

دانشکده مهندسی برق و کامپیوتر

استاد درس:

دستورکار آزمایشگاه هوش محاسباتی
جلسه

اهداف این جلسه

- ساخت یک دسته‌بند حالات با استفاده از TF Keras Sequential API
 - ساخت یک ConvNet برای شناسایی اعداد زبان اشاره با استفاده از TF Keras Functional API
- در پایان این جلسه شما قادر خواهید بود که :
- برای دسته‌بندی دوتایی، یک ConvNet را ساخته و آموزش دهید.
 - برای دسته‌بندی چند کلاسه، یک ConvNet را ساخته و آموزش دهید.
 - تفاوت موارد استفاده از Sequential و Functional API ها را شرح دهید.

۱ آماده‌سازی

در ابتدا، همانطور که در فایل ژوپتر مشاهده خواهید کرد، باید پکیج‌های مربوطه را فراخوانی کنیم. شما در این تمرین از مجموعه داده‌ی Happy House استفاده خواهید کرد. این مجموعه داده حاوی تصاویر RGB با اندازه‌ی 64x64 پیکسل از صورت‌های افراد است. وظیفه‌ی شما ساختن یک شبکه‌ی پیچشی است که تشخیص دهد آیا صورت‌ها در حال لبخند زدن هستند، یا خیر.

۲ لایه‌ها در TF Keras

در جلسه‌ی قبل، شما لایه‌ها را بصورت دستی با numpy پیاده‌سازی کردید. در Keras شما نیازی به نوشتن کد به صورت مستقیم برای این کار ندارید و Keras بصورت از پیش تعریف شده، لایه‌هایی را دارد که می‌توانید از آن‌ها استفاده کنید.

۳ Sequential API

در جلسه‌ی قبل، شما برای درک ساختار شبکه‌ی عصبی پیچشی، توابع کمکی‌ای را با استفاده از numpy ساختید. بسیاری از اپلیکیشن‌های مبتنی بر یادگیری عمیق، با استفاده از چهارچوب^۱ های برنامه‌نویسی‌ای ساخته شده که درون خود، تعداد زیادی تابع از پیش نوشته شده دارند که به راحتی قابل فراخوانی هستند. Keras یک چهارچوب ساخته شده بر روی TensorFlow است که برای ما امکان استفاده‌ی راحت‌تر و بهینه‌تر از مفاهیم ساخت مدل و آموزش آن را فراهم می‌سازد. برای قسمت اول این تمرین، شما یک مدل را با استفاده از Keras' Sequential API خواهید ساخت. با این کار شما قادر خواهید بود که مدل خود را بصورت لایه به لایه بسازید. ساخت مدل بصورت لایه به لایه برای کاربردهایی که مدل شما دقیقاً یک تنسور ورودی و یک تنسور خروجی دارد، بسیار ایده‌آل خواهد بود. همانطور که در ادامه خواهید دید، استفاده از Sequential API ساده و سراسر است، اما فقط برای وظایف ساده، کارایی دارد. در ادامه‌ی این تمرین‌ها، شما با استفاده از Functional API جایگزینی انعطاف‌پذیرتر و قدرتمندتر خواهید ساخت.

۱.۳ ساخت مدل ترتیبی

همانطور که اشاره کردیم، TensorFlow Keras Sequential API می‌تواند برای ساخت مدل‌های ساده که بصورت ترتیبی پیش می‌روند، استفاده شود. شما همچنین می‌توانید با استفاده از تابع `.add()` لایه‌هایی را به مدل خود اضافه کنید یا با استفاده از `.pop()` آن‌ها را حذف کنید. درست شبیه به لیست‌های معمولی در پایتون. درواقع مدل ترتیبی بسیار شبیه به لیست‌های پایتون است. اگر مدل شما غیر خطی است یا شامل لایه‌هایی با چندین ورودی و خروجی است، استفاده از مدل ترتیبی، گزینه‌ی خوبی نیست. برای ساخت هر لایه در Keras، شما باید شکل ورودی را مشخص کنید. این کار به این دلیل است که در Keras، شکل وزن‌ها بستگی به شکل ورودی‌ها دارد. وزن‌ها زمانی ساخته می‌شوند که مدل ابتدا تعدادی داده‌ی ورودی را مشاهده کند. مدل‌های ترتیبی می‌توانند با استفاده از فرستادن لیستی از لایه‌ها به سازنده‌ی ترتیبی^۲، ساخته شوند. موضوع تمرین بعدی، همین است.

^۱framework

^۲Sequential constructor

تمرین اول: happyModel

در فایل ژوپیتر این جلسه، در قسمت Exercise 1 - happyModel تابع `happyModel` را به منظور ساخت مدل زیر، تکمیل کنید:

از این `tf.keras.layers` `DENSE -> FLATTEN -> MAXPOOL -> RELU -> BATCHNORM -> CONV2D -> ZEROPAD2D` برای راهنمایی می‌توانید

همچنین پارامترهای زیر را برای همه مراحل، به کار ببرید:

- `ZeroPadding2D`: لایه‌گذاری 3×3 ، شکل ورودی: $64 \times 64 \times 3$

- `Conv2D`: از 3×3 فیلتر 7×7 با گام 1×1 استفاده کنید.

- نرمالسازی دسته ای 5 : برای محور 3

- `ReLU`

- `MaxPool2D`: با استفاده از پارامترهای پیش فرض

- `Flatten`: خروجی قبلی

- لایه ی `Dense` Fully-connected: یک لایه ی fully connected با یک نورون و فعالساز سیگموید

راهنمایی: برای مختصرنویسی می‌توانید از `tfl` بجای `tensorflow.keras.layers` استفاده کنید.

بعد از ساخته شدن مدل‌تان، می‌توانید آن را با استفاده از یک بهینه‌ساز و تابع هزینه دلخواه، برای آموزش، کامپایل کنید. هنگامی که رشته‌ی `accuracy` به عنوان یک سنج، انتخاب شود، نوع آن، بر اساس نحوه استفاده‌ی تابع هزینه، به طور خودکار، تبدیل خواهد شد. این عمل، یکی از انواع بهینه‌سازی‌هایی است که در TensorFlow بصورت آماده، طراحی شده است. برای اطلاعات بیشتر، می‌توانید این لینک را مشاهده کنید سپس برای ارزیابی پارامترهای مدل خود، می‌توانید از `summary()` استفاده کنید. با این کار، شما قادر خواهید بود که نوع لایه‌هایی که دارید، شکل خروجی‌ها و تعداد پارامترهای هر لایه را مشاهده کنید. خروجی، چیزی شبیه ذیل خواهد شد:

Model: "sequential"

Layer (type)	Output Shape	Param #
zero_padding2d_1 (ZeroPaddin	(None, 70, 70, 3)	0
conv2d (Conv2D)	(None, 64, 64, 32)	4736
batch_normalization (BatchNo	(None, 64, 64, 32)	128
re_lu (ReLU)	(None, 64, 64, 32)	0
max_pooling2d (MaxPooling2D)	(None, 32, 32, 32)	0
flatten (Flatten)	(None, 32768)	0
dense (Dense)	(None, 1)	32769

Total params: 37,633
Trainable params: 37,569
Non-trainable params: 64


۲.۳ آموزش و ارزیابی مدل

بعد از ساختن و کامپایل کردن مدل با هزینه و بهینه‌ساز دلخواه، می‌توانیم مدل خود را آموزش دهیم و آن را ارزیابی کنیم. برای آموزش مدل، کافیت از `fit()` استفاده کنید. شما این اختیار را دارید که شماره‌ی `epoch` یا اندازه‌ی `minibatch` را تغییر دهید. (به طور مثال برای یک مجموعه داده‌ی `unbatched`) سپس می‌توانید با استفاده از `evaluate()` مدل خود را در مقابل مجموعه‌ی آزمون، ارزیابی کنید. این تابع مقدار تابع هزینه و پارامترهای معیاری که در حین کامپایل شدن، مشخص شده اند را چاپ خواهد کرد که در مثال ما، مقادیر آن به ترتیب، `binary_crossentropy` و `accuracy` خواهد بود.


padding^۳
stride^۴
BatchNormalization^۵

۴ Functional API

در این قسمت قصد داریم با استفاده از Functional API یک شبکه ی پیچشی را برای تمیز دادن ۶ شماره در زبان اشاره، بسازیم. Functional API قابلیت اداره کردن مدلهایی با توپولوژی غیرخطی و لایه های اشتراکی مانند لایه هایی با چندین ورودی و خروجی را داراست. اگر مدل ترتیبی را بصورت یک خط در نظر بگیریم، آنگاه می توان مدل تابعی را بصورت یک گراف در نظر گرفت که گره های آن می توانند به روش های زیادی به همدیگر متصل شوند. در مثال تصویری زیر، یک جهت احتمالی مدل ترتیبی، حرکت در مقابل اتصال skip نشان داده شده است، که تنها یکی از روش های متعددی است که می توان یک مدل Functional ایجاد کرد. اتصال skip، همانطور که احتمالاً حدس زده باشید، تعدادی از لایه ها را رد می کند و خروجی را توسط لایه های بعدی، تغذیه می کند.



Sequential Movement



Skip Connection

۱.۴ بارگزاری مجموعه داده ی SIGNS

مجموعه داده ی SIGNS حاوی مجموعه ای از ۶ نشانه از اعداد ۰ تا ۵ می باشد. کد این قسمت در فایل ژوپیتِر جلسه، در بخش ۱.۴ پیاده سازی شده است و در قسمت بعدی کد، یک نمونه از تصویر برجسب گذاری شده را خواهید دید.
تصویر ۲

۲.۴ تقسیم داده ها به مجموعه ی آموزشی و آزمون

در فایل این جلسه، در قسمت ۲.۴، کد مربوط به تقسیم داده ها به دو قسمت آموزشی و آزمون را مشاهده می کنید. از آنجایی که مجموعه داده ی ما، شامل داده های تصویری است، طبیعی است که یک ConvNet بر روی آن اعمال کنیم.

۳.۴ انتشار پیش رو

در TensorFlow توابع از پیش ساخته شده ای وجود دارند که مراحل پیش را برای شما پیاده سازی خواهند کرد. تا اینجا شما باید با نحوه ی ساخته شدن گراف های محاسباتی توسط TensorFlow آشنا شده باشید. در Functional API شما گرافی از لایه ها می سازید و این کار به مدل شما انعطاف زیادی می دهد. اگرچه، مدلی که در ادامه خواهیم دید، می تواند با استفاده از مدل ترتیبی نیز تعریف شود زیرا جریان اطلاعات در این مورد به صورت خطی است. اما برای یادگیری، از Functional API استفاده خواهیم کرد. برای ساخت گراف خود، از ساخت یک گره ی ورودی که به صورت یک تابع قابل فراخوانی عمل می کند، کار خود را آغاز کنید.

- `input_img = tf.keras.Input(shape=input_shape)`
سپس با فراخوانی یک لایه بر روی شیء `input_img`، یک گره جدید بر روی گراف لایه ها ایجاد کنید.
- `tf.keras.layers.Conv2D(filters= ..., kernel_size= ..., padding='same')(input_img) :`
توضیحات بیشتر در [Conv2D](#)

- `tf.keras.layers.MaxPool2D(pool_size=(f, f), strides=(s, s), padding='same')`
ورودی خود را با استفاده از یک پنجره با اندازه (f,f) و گام های به اندازه (s,s) برای انجام max pooling بر روی هر پنجره، نمونه برداری می کند.
- `tf.keras.layers.ReLU()`:
مقدار نظیر به نظیر درایه ای `ReLU of Z` (که می تواند هر شکلی داشته باشد) را محاسبه می کند. توضیحات بیشتر در `ReLU`
- `tf.keras.layers.Flatten()`:
با داشتن تانسور `P` این تابع به صورت دسته ای، هر نمونه ی آموزشی یا آزمون را می گیرد و در خروجی یک بردار یک بُعدی به ما می دهد. توضیحات بیشتر در `Flatten`
- `tf.keras.layers.Dense(units= ..., activation='softmax')(F)`:
با داشتن ورودی مسطح شده ی `F`، خروجی ای را که با استفاده از یک لایه ی تمام متصل، محاسبه شده است، برمیگرداند. توضیحات بیشتر در `Dense`
در آخرین تابعی که در بالا آمده است، لایه ی `fully connected` بصورت خودکار، وزن ها را در گراف مقداردهی اولیه میکند و سپس به آموزش آنها در حین آموزش مدل، ادامه میدهد. از این رو، شما به مقداردهی اولیه به آن وزن ها در هنگام مقداردهی اولیه به پارامترها، نیاز پیدا نکردید.
در نهایت، قبل از ایجاد مدل، باید خروجی را با استفاده از آخرین ترکیب تابع تعریف کنید (در اینجا، لایه ی `Dense`):
- `outputs = tf.keras.layers.Dense(units=6, activation='softmax')(F)`

پنجره، کرنل، فیلتر، تجمیع

کلمات `کرنل` و `فیلتر` هر دو به یک موضوع اشاره می کنند. کلمه ی `فیلتر` تعداد `کرنل` هایی که در یک لایه ی پیچشی استفاده خواهند شد را، مشخص می سازد تجمیع اسم عملیاتی است که بیشینه یا متوسط `کرنل` ها را می گیرد.

به همین دلیل است که پارامتر `pool_size` به `kernel_size` اشاره دارد و شما از `(f,f)` برای اشاره به اندازه فیلتر استفاده می کنید. اندازه تجمیع و اندازه `کرنل` هر رو به یک چیز ولی در موضوعات مختلف - به شکل پنجره ای که عملیات در آن در حال انجام است - اشاره می کنند.

تمرین دوم: convolutional_mode

در فایل ژوپیتر این جلسه، در قسمت `Exercise 2-convolutional_model` تابع `convolutional_model` زیر را با توجه به مدل `CONV2D -> RELU -> MAXPOOL -> CONV2D -> RELU -> MAXPOOL -> FLATTEN -> DENSE` تکمیل کنید. از توابعی که در بالا به آنها اشاره کردیم، استفاده کنید. در حین این کار، از پارامتر های زیر استفاده کنید:

• Conv2D: 8 4x4 filters, stride 1, padding=SAME

• ReLU

• MaxPool2D: 8x8 filter size, 8x8 stride, padding=SAME

• Conv2D: 16 2x2 filters, stride 1, padding=SAME

• ReLU

• MaxPool2D: 4x4 filter size, 4x4 stride, padding=SAME

• Flatten the previous output

• Fully-connected (Dense) layer: یک لایه ی تمام متصل با ۶ نورون و فعالساز سافت-مکس را اعمال کنید.

هر دو روش ترتیبی یا تابعی، یک شیء از نوع `TF Keras mode` برمی گردانند. تنها تفاوت این دو این است که ورودی ها چگونه در آنها مدیریت می شوند.

۴.۴ آموزش مدل

در فایل این جلسه در کد قسمت ۴.۴ شما مدل خود را آموزش می دهید.

۵ History Object

شیء `history` یکی از خروجی های `.fit()` است و اطلاعات هزینه ها و مقادیر متریک را در حافظه نگهداری می کند. این مقدار به صورت یک واژه نامه ذخیره شده است که می توانید آن را توسط `history.history` بازیابی کنید و سپس مقدار هزینه را نسبت به زمان با استفاده از آن نمایش دهید